

Detecção e contagem de frutas em imagens de robô

Teste técnico — AI Engineer (Computer Vision) · Antoniq Robotics · código e detalhe de engenharia no `README.md` do repositório

Resumo — seis conclusões, cada uma medida. (1) O split é o resultado (§2): as 670 imagens são quadros de dez vídeos; um split aleatório reportaria **AP50 0,81** onde o split por sessão entrega **0,55**, inflando **+75,5%** o AP-small, que é 69,5% deste dataset. **(2) O tiling perdeu, e não é defeito do tiling (§4):** imagem inteira a 640 vence em todas as colunas e custa **8× menos** que recortes de 320 — os pesos foram treinados em imagem inteira, e o recorte joga a fruta para 4× a escala de treino. **(3) O IoS resolve a duplicata de borda, mas não melhora a contagem (§4):** contra o IoU vence em **76%** dos pareamentos em precisão e **0%** em recall — e na MAE, em apenas **34%**. **(4) Uma única sessão responde por 52,7% dos falsos negativos (§5),** a 2,29× a taxa média: o gargalo é deriva de domínio entre dias, não arquitetura. **(5) A análise de erro apontou um alvo e o alvo respondeu (§6):** ampliar a augmentação de brilho até cobrir a faixa das sessões que falham comprou **-16,2% de MAE**, mais do que quadruplicar os parâmetros. **(6) Veredito: NO-GO (§5) —** o viés agregado é **-2,0%** e passa na trava de 3%, mas a pior sessão erra **+166%** e reprova. É por isso que o critério tem três travas e não uma.

1. Dataset e limitações

MinneApple, subconjunto de detecção — escolhido em vez de um conjunto de morango do Roboflow por reunir três coisas que nenhum deles tem junto: baselines publicados; imagens que são quadros de um percurso ao longo de fileiras, a geometria de captura de um robô; e nomes de arquivo que preservam sessão e índice de quadro, o que viabiliza o split honesto e o bônus de deduplicação.

São **670 imagens rotuladas** de 720×1280 (retrato), com **28.182 instâncias**, 42,1 maçãs por imagem e até **123** numa só. O lado mediano da caixa é de **~27 px**: 69,5% do dataset cai na faixa *small* do COCO, 30,5% em *medium* e **0% em large**.

Limitações declaradas. Maçã não é framboesa — o que transfere é o método, não os números. A licença é **não comercial**. O split de teste oficial tem rótulos retidos, então todas as métricas vêm de validação cruzada sobre as 670 rotuladas, protocolo mais duro que o do artigo e não comparável a ele. Não há objeto *large*, então **AP_large** é indefinido. E, o mais consequente: **a anotação cobre apenas fruta em árvore de primeiro plano** — fruta no chão e ao fundo fica sem rótulo. Não é ruído, é decisão de escopo que penaliza detecção correta, e vira o modo de erro nº 1 da §5.

O artigo descreve as imagens como " 1280×720 ". A verificação dos 1001 arquivos mostra **720 de largura por 1280 de altura** — o artigo escreve altura $\times$ largura. Propagada para dentro de um transform de coordenada, essa inversão troca todas as caixas sem levantar erro.


2. Metodologia: o split é o resultado mais importante

As 670 imagens **não são independentes**. São quadros de dez vídeos, gravados caminhando a ~ 1 m/s ao longo de fileiras, com um quadro a cada cinco — cerca de **17 cm entre imagens vizinhas**. O nome do arquivo entrega a sessão: `20150921_131453_image1101.png`.

E as sessões são regimes distintos, não amostras: a densidade varia de **21,9 a 98,1 maçãs por imagem** e o brilho de 100 a 143 por imagem — ou, medido só **dentro das caixas**, de 54 a 166, com as duas sessões de 19/09 sozinhas acima de 164.

Um split aleatório por imagem coloca quadros quase idênticos em treino e teste. Num baseline aleatório treinado de propósito para medir isso, **10 das 10 sessões aparecem simultaneamente em treino e teste do mesmo fold**. O vazamento é total, não parcial.

O que foi feito: GroupKFold sobre as sessões, três folds (364/378/392 de treino). Cada imagem é testada exatamente uma vez, o que permite agregar sobre as 670 e ainda reportar desvio entre folds. **A validação também sai de uma sessão inteira e separada** — usar quadros do mesmo vídeo do treino para early stopping reintroduziria o vazamento pela porta dos fundos.



Composição dos folds por sessão de captura. Cada sessão aparece em exatamente um papel por fold — a evidência visual de que nenhuma cruza treino, validação e teste.

Quanto isso custaria em métrica inflada? A evidência estrutural já basta para rejeitar o split aleatório — 10/10 sessões em ambos os lados não é um vazamento parcial que se possa descontar. Para além disso, um modelo foi treinado com split aleatório e avaliado **nas mesmas imagens** do teste agrupado, o que remove a diferença de composição do conjunto:

Split	AP	AP50	AP-small	F1	MAE	viés
aleatório (vazado)	0,395	0,812	0,333	0,781	8,6	+20,0%
agrupado (honesto)	0,259	0,548	0,190	0,625	20,5	-5,1%
inflação	+52,4%	+48,1%	+75,5%	+25,1%	-57,8%	

A maior inflação é em **AP-small**, a faixa que representa 69,5% deste dataset: é a métrica que mais importa aqui e a que mais mente. E o modelo vazado ainda tem **+20,0% de viés** — pelo critério da §3 ele reprovaria antes de qualquer discussão de MAE, e o "erro cortado pela metade" é sobrecontagem sistemática, não competência. *É um limite superior: o delta soma vazamento de quadro, cobertura de domínio e early stopping sobre uma validação também sorteada; separá-los exige o braço de controle da §8.*

Separação entre escolher e medir. Braço, limiar e política de fusão são escolhidos **na validação**, por fold; o teste do fold k só é lido depois, no ponto que a validação do fold k congelou (§4). Sem isso o número reportado seria um mínimo sobre milhares de combinações calculado no próprio conjunto de avaliação — e o caso mais indefensável seria o critério da §3, que exige $|\text{viés}| \leq 3\%$: a varredura escolheria o limiar de menor viés no teste e o critério passaria por construção. A regra usada é **menor MAE sujeito a $|\text{viés}| \leq 3\%$** , que espelha o critério.

3. Baseline e a métrica de aceitação

YOLO26n treinado a 640 px — 2,5 M parâmetros e 5,8 GFLOPs, medidos no próprio checkpoint. O tamanho que um Jetson roda. Escolhido pela viabilidade em edge: atribuição de rótulo ciente de alvo pequeno (STAL), cabeça NMS-free e export limpo para TensorRT por não levar DFL no grafo.

AP@[.5:.95]	AP@0,50	AP-small	AR@300	F1	MAE	MAPE	latência
0,287 ± 0,076	0,621 ± 0,164	0,206 ± 0,055	0,389	0,622 ± 0,106	21,4 ± 9,4	65,9%	16 ms

± é o desvio entre os três folds: variação entre sessões de captura, não incerteza do estimador. Não é intervalo de confiança.

Duas colunas dizem mais que o AP: **$R^2 = -0,257$** e **inclinação = 0,358**. O R^2 negativo significa que prever a contagem média seria melhor que o sistema; a inclinação diz por quê — a contagem prevista cresce só 0,36 por unidade de contagem real. **O modelo comprime.** (O r^2 da regressão previsto ~ real daria **+0,132**, bem mais lisonjeiro — são medidas diferentes, e reportar a gentil esconderia o defeito.)

Qual métrica eu usaria como limiar de aceitação

Não seria mAP. Ele é livre de limiar e dominado por qualidade de localização em IoU alto. Um produto de contagem roda em **um** ponto de operação, e o cliente não compra precisão de caixa — compra um número de frutas.

Métrica principal: erro relativo de contagem na unidade de agregação do negócio — por planta ou por fileira, não por imagem. Mais duas travas. **Viés**, porque ao somar ao longo de uma fileira o erro aleatório se cancela e o viés se acumula. E **F1 no ponto de operação**, contra a armadilha central: um falso positivo e um falso negativo na mesma imagem se cancelam e o erro de contagem vai a zero — MAE baixa pode ser competência ou sorte, e só o F1 separa.

Go/no-go para uma V1: erro relativo médio por fileira $\leq 10\% \cdot |\text{viés}| \leq 3\%$ · nenhuma condição (luz, variedade, data) acima de 15%.

4. Inferência em alta resolução

Quatro estratégias, **os mesmos pesos** — a variável controlada é a inferência. Cada braço avaliado no teste, no ponto que a **validação** escolheu para ele:

Braço	passes	redundância real	AP	AP50	F1	MAE	latência
A · imagem 640 ✓	1	1,00×	0,287	0,621	0,622	21,4	16 ms
B · imagem 1280	1	1,00×	0,246	0,537	0,537	31,1	23 ms
C · tile 640	6	2,67×	0,204	0,463	0,532	29,7	57 ms
D · tile 320	15	1,67×	0,045	0,135	0,177	49,0	130 ms

✓ braço congelado — e o único cujo viés de teste (-2,0%) cabe na trava de 3% da §3.

Duas correções de protocolo que este número exigiu, e que valem mais que ele. **(i)** A grade de limiares tinha passo 0,05 e não amostrava a própria restrição que impunha: o viés do braço A é monótono em `conf` e cruza zero entre 0,12 e 0,14, então a grade saltava de +10,3% para -4,1% e o braço aparecia como **inviável** sob $|\text{viés}| \leq 3\%$ — com o passo em 0,01, os quatro braços são viáveis. **(ii)** A seleção usava a união das três validações e a avaliação usava a união dos três testes; como a sessão de validação de cada fold é sessão de **teste** de outro, **206 das 670 imagens de teste (30,7%) estavam no pool que escolhia braço, limiar e política.** A seleção passou a ser por fold, e o fold k é lido no ponto que a validação do fold k escolheu. O `assert` de vazamento não pegava: ele verifica dentro de um fold, e este nascia na agregação. Custo da correção no braço B: MAE **23,5** → **31,1** e viés **+5,0%** → **+13,8%**.



Recortes de 460 px em três casos: onde o tiling mais ajuda (cena densa de 70 maçãs — corta 57 falsos positivos), o caso mediano, e onde mais atrapalha (cena esparsa de 18 maçãs — 126 falsos positivos contra 21). Verde = TP, vermelho = FP, laranja = FN; as contagens nos títulos são do quadro inteiro.


O tiling perde em todas as colunas e custa de 3,7× a 8,3× mais. A conclusão honesta não é "tiling não serve", e sim que **para um modelo treinado em imagem inteira a 640 o tiling joga o objeto para fora da distribuição de treino**. Dois confundidores, declarados. **(i)** Os pesos favorecem o braço A: a maçã vista no treino tem mediana de 13,6 px, e na inferência a rede vê 13,6 px no A, 27,3 no B e no C e **54,6 no D** — 4,0× a escala de treino contra 1,5× de cobertura da augmentação; se o D perde, é da receita. **(ii)** A sobreposição configurada não é a real: um tile de 640 não cabe duas vezes em 720, a grade colapsa, e o braço C tem sobreposição real de **0,875 em x** (não 0,2), olhando cada pixel **2,67 vezes** contra 1,67 do D — parte do que ele ganha é *ensemble*. Vale explicitar o que raramente se diz: **recortar em 640 e alimentar a rede em 640 não aumenta o objeto** — o C só reduz a densidade por passe, e a magnificação real só aparece no D.

O ponto técnico: IoU não serve para fundir entre tiles

Uma fruta cortada pela aresta de um tile produz uma caixa com ~metade da área da que o tile vizinho gera para a mesma fruta. O **IoU** entre as duas fica em torno de 0,45–0,50 — em cima do limiar usual, e a duplicata escapa de forma imprevisível. O **IoS** (interseção ÷ área da **menor** caixa) dá ~1,0 e a remove sem ambiguidade.

Não é detalhe acadêmico: o baseline *Tiled Faster R-CNN* do próprio artigo do MinneApple ficou **abaixo** da inferência em imagem inteira (AP 0,341 vs 0,438), e os autores atribuem a perda ao passo de supressão. A ablação varre o braço C em **24 políticas × 90 limiares × 3 folds**, e cada eixo abaixo é marginalizado sobre ela:

Métrica: IoS dá MAE **30,61** contra **32,11** do IoU, e precisão **0,718** contra 0,705 — mas recall 0,509 contra **0,515**, o único eixo em que ele perde. **Política:** NMM (união) **31,21** contra 31,51 do NMS. **Borda:** descartar truncadas **31,13** contra 31,60.



Comparação PAREADA: para cada configuração idêntica em política, limiar de casamento, descarte de borda, limiar de confiança e fold, quem venceu. A linha tracejada é o empate. O IoS domina em precisão e fica **ABAIXO** dela na MAE de contagem — é a dissociação inteira numa figura. Marginalizar a MAE sobre a grade de confiança daria um número que não corresponde a ponto de operação nenhum: acima de conf 0,7 o detector quase não devolve caixa, a MAE tende à contagem real e a política de fusão deixa de importar.

O IoS faz o que promete, e isso não basta. Pareado configuração a configuração (**3.240 pares**: 12 configurações de fusão × 90 limiares × 3 folds), ele vence o IoU em **77% dos casos em precisão** e **65% em F1** — mas em **0,4%** em recall (12 de 3.240): ele sempre remove mais. É a confirmação direta do mecanismo, e é o que se quer de um controle de duplicata. **Na MAE de contagem, porém, o IoS vence em apenas 37%**, e no regime que interessa — os limiares onde o viés cabe em 3% — os dois empatam (**9,92 contra 9,96**). Num sistema que já subconta, remover mais caixas empurra a contagem para o lado errado.

Uma versão anterior desta seção afirmava "IoS bate IoU em 12 de 12". Aquilo foi medido numa grade de 13 limiares; com 90, a afirmação não sobrevive. **O ganho do IoS é de qualidade de detecção, não de contagem** — a mesma dissociação que a §3 usa para rejeitar o mAP como critério de aceitação, aparecendo agora no eixo da fusão. A pior combinação continua sendo `iou-nms@0.7-keep` (MAE 111,8), a mais próxima do que o baseline do artigo fazia.

Onde o tiling machuca. Fruta mais larga que a faixa de sobreposição não é vista inteira por tile nenhum e vira duas detecções — regime real mas pequeno aqui: a fruta mais larga do dataset tem **81 px** (a mais alta, 89) e só **0,23% delas** excedem a faixa de 64 px do tile 320. O modo de falha que domina é outro: em cena esparsa com fundo visível, o tiling magnifica árvore de fundo e céu e produz **126 falsos positivos contra 21** da imagem inteira (18 maçãs anotadas, contagem 143 contra 37). E mesmo onde o tiling *ajuda*, o ganho não é recall: numa cena de 70 maçãs ele recupera 7 detecções perdidas e **corta 57 falsos positivos** — o benefício vem de suprimir excesso, não de enxergar mais.

5. Contagem e modos de erro

O agregado mente; o pior caso denuncia

O braço congelado erra a contagem agregada em **-2,0%** — dentro da trava de 3%. E é a única trava que ele cumpre: o agregado esconde o que acontece por dentro.

Sessão	maçãs/img reais	previstas/img	erro
20150919_174151	98,1	14,2	-85%
20150919_174730	31,2	14,3	-54%
(oito sessões de 21/09)	21,9 a 57,3	34,3 a 64,3	-6% a +166%

As duas sessões de **19/09** subcontam; as oito de **21/09** sobrecontam. É deriva de domínio entre dias de captura, não erro aleatório — e é a mesma compressão que a inclinação 0,358 mostra.

Aplicando o critério da §3: erro médio por sessão **54,3%** (reprova), pior sessão **166%** (reprova), amplitude **251 pontos** — e viés agregado **-2,0%**, que **passa**. A aprovação isolada do viés é o argumento inteiro: um sistema que erra de -85% a +166% entre dias de captura exhibe um agregado de -2% e passaria numa revisão que olhasse só o total.


E a decomposição é exata (previsto - real = FP - FN): **10.229 falsos negativos** (recall 63,7%) contra **10.769 falsos positivos** (16,1 por imagem). O erro **líquido** é de **+540** — o que aparece na contagem — enquanto o **bruto** é **20.998, trinta e nove vezes maior**. A diferença entre os dois é cancelamento, não acerto.

Um detalhe que vale explicitar, porque os dois números convivem no texto: esta decomposição é calculada num **limiar único congelado** (conf 0,13, o de `operating_point.json`), para que os estratos da §7 sejam comparáveis entre si; o viés de **-2,0%** acima vem da tabela dos braços, onde cada fold é lido no limiar que a **validação daquele fold** elegeu — média 0,163. É a mesma imagem, o mesmo modelo e a mesma política de fusão; muda só o ponto de operação. Três centésimos de limiar viram **1.100 maçãs** de diferença e **invertem o sinal** do viés agregado, de -2,0% para +1,9%. Não é contradição: é a sensibilidade que a calibração abaixo mede, e é a razão de o ponto de operação ser um artefato versionado em vez de um número escolhido no fim.

Calibração: o ótimo de detecção não é o ótimo de contagem. Varrendo 90 limiares na validação, o braço congelado maximiza F1 em **0,22** e minimiza a MAE de contagem em **0,13** — e o viés cruza zero nesse mesmo 0,13. Não são três pontos, são **dois**, e a distância entre eles é o que custa: no limiar que otimiza F1 o sistema **subconta 17,0%**; no que otimiza a contagem, o viés é **+0,8%** e o F1 cai de 0,750 para 0,734. Calibrar por F1 e reportar contagem descreve um sistema que nunca foi configurado assim. (Números em `results/calibration_optima.json`; curvas em `results/figures/05_calibracao.png`.)

Ranking dos modos de erro

Ordenado por **excesso de perda sobre a taxa média**, não por contagem bruta — ordenar por contagem elege o estrato mais *populoso*, que costuma ser o mediano e não o problemático.



Ranking dos modos de erro. À direita, em vermelho, a sobrecontagem por detecção sem anotação — **+10.769 maçãs, 51,3%** de todo o erro. À esquerda, em azul, o que cada estrato tira da contagem; entre parênteses, a taxa de perda dentro dele. O eixo é **maçã de erro**, não número de casos, e é isso que amarra o modo de erro à métrica do produto. A sessão 20150919_174151 perde **83,2%** da sua fruta, **2,29×** a taxa média; **small** perde **44,6%** de 19.581 frutas.

Uma única sessão é o modo dominante: perde 83,2% da sua fruta, a 2,29× a taxa média. Uma versão anterior desta tabela excluía o fator "sessão" do ranking e concluía que a perda se concentrava em oclusão — deixando no lugar o proxy "iluminação", que está confundido com sessão. Removido o confundidor real, a conclusão invertia. **Em maçãs**, o maior contribuinte de subcontagem é **small** (-8.731); **em intensidade**, é a sessão (2,29×). Os dois números respondem perguntas diferentes e o relatório precisa dos dois. Os demais fatores que o enunciado pede aparecem todos na figura, e nesta ordem de intensidade: **iluminação** (1,34× a taxa média), **aglomeração em cacho de 6-10 frutas** (1,22×, -3.702 maçãs), **borda** (1,14×) e **occlusão** por solidez (1,12×). O intervalo entre eles é estreito — o que separa o problema não é o fator, é a **sessão**. Ressalva: os fatores se sobrepõem e as frações não somam 1 — é uma lista de lentes, não uma decomposição.

As duas correções que eu faria — no dado, não no modelo

1. O escopo de anotação está indefinido, e isso treina o modelo a errar. Fruta no chão e em árvores de fundo fica sem rótulo, então o modelo aprende a *suprimir* maçãs reais e toda detecção de fundo vira falso positivo — os **10.769 FP**, o

maior item do ranking, incluem fruta correta que o protocolo decidiu não contar. *Correção*: atributo explícito de **plano** no schema, e melhor ainda capturar com **RGB-D ou estéreo de baseline fixa**, definindo o plano de contagem por **geometria em vez de julgamento do anotador**. Num corredor de estufa, um corte por profundidade elimina a classe de erro inteira.

2. A regra de fração mínima visível não existe — e ela é quantificável. O ground truth tem falsos negativos próprios (anotador único, 30 min por imagem), então a taxa de perda está inflada e parte dos "falsos positivos" é fruta real. Pior, a ausência da regra se propaga: ao montar os recortes de 320 px com corte em 35% de visibilidade, **2.456 maçãs visíveis ficaram sem rótulo — 9,32% de toda a fruta visível nos tiles de treino**, ensinando "fruta cortada = fundo". *Correção*: fixar a fração mínima no schema (ex.: $\geq 20\%$), e **dupla anotação cega com adjudicação** numa subamostra estratificada, publicando a concordância inter-anotador como **piso de ruído** — sem ele não há como saber se o modelo bateu no teto do dado. Para framboesa, que agrupa muito mais que maçã, é o risco número um.

6. Experimentos: qual alavanca move a agulha

Oito conjuntos de pesos, todos medidos **pelo pipeline inteiro** — recorte, detecção, fusão, contagem — no mesmo teste, cada um no braço e no limiar que a **sua** validação escolheu:

pesos	braço	MAE	MAPE	viés	F1	recall	AP50	AP-small
YOLO26s @1280 + aug (9,9 M)	B_full1280	12,6	27,8%	-18,3%	0,752	0,683	0,762	0,352
YOLO26s @1280 (9,9 M)	B_full1280	15,1	29,6%	-28,4%	0,738	0,633	0,742	0,337
YOLO26m @1280 + aug (21,8 M)	B_full1280	19,3	30,0%	-34,6%	0,695	0,575	0,683	0,314
YOLO26n @1280, 90 ép	B_full1280	24,7	36,1%	-47,1%	0,634	0,484	0,643	0,290
recortes de 320 px	D_tile320	26,6	40,7%	-50,7%	0,607	0,453	0,487	0,227
YOLO26n @1280, 124 ép	A_full640	31,1	55,4%	-58,9%	0,507	0,358	0,463	0,157
YOLO11s @640 (9,4 M)	A_full640	33,0	47,2%	-62,2%	0,474	0,327	0,475	0,204
baseline @640 (2,5 M)	A_full640	33,2	54,6%	-62,6%	0,465	0,319	0,439	0,158

Do baseline ao melhor: MAE -62,0%, recall +113,9%, AP-small +122,8%, com a precisão custando apenas 2,1% (0,854 → 0,836). O viés sai de -62,6% para -18,3%.

Resolução primeiro, capacidade depois, e ambas saturam. A 640 px a maçã mediana chega à rede com 13,6 px e não há sinal para um modelo maior usar: o YOLO11s, com 4× os parâmetros, empata com o baseline (33,0 contra 33,2). A 1280 px ela chega com 27 px e a capacidade paga — 2,5 M → 9,9 M leva a MAE de 24,7 para 15,1. **O degrau seguinte não paga**, e a comparação é limpa: 9,9 M e 21,8 M com **a mesma augmentação** dão **12,6 contra 19,3**. **O joelho está em ~10 M**, coerente com 450 imagens de treino — acima disso o modelo decora as seis sessões.

A alavanca que mais pagou não foi capacidade — foi a augmentação que a §5 encomendou. Os dois YOLO26s têm treino idêntico — modelo, resolução, batch, orçamento de épocas, paciência, semente — menos a augmentação: `hsv_v 0,40 → 0,75, hsv_s → 0,90, scale 0,5 → 0,35, close_mosaic 30`. **MAE 15,1 → 12,6 (-16,2%)**, recall +7,8%, viés de -28,4% para -18,3%. O brilho é a peça que a §5 encomendou e está medida em `dataset_summary.json`: o V médio **dentro das caixas** é 98,2 nas seis sessões de treino e **164 / 166** nas duas de 19/09, que são as que o modelo mais erra — com `hsv_v = 0,40` o treino alcança $98,2 \times 1,40 = 137$ e nunca vê aquela faixa; com 0,75 alcança **172**. *As quatro mudanças entraram juntas, então o ganho é da receita e não isoladamente do brilho — o teste que separaria as peças é uma varredura de um fator por vez, que não coube*. Ainda assim, a análise de erro apontou um alvo e o alvo respondeu: é a justificativa mais forte deste relatório para gastar o dia em diagnóstico antes de gastá-lo em arquitetura.

A correção mais útil deste relatório. Comparando o mesmo YOLO26n a 1280 px com 90 e com 124 épocas, o mAP de validação fica parado — 0,4478 contra 0,4480. Pelo mAP, épocas extras não comprariam nada. No **teste, com o pipeline completo**, a MAE cai de **24,7 para 19,1 (-22,8%)** e o F1 sobe de 0,634 para 0,715. Uma decisão de "parar de treinar" tomada pelo mAP de validação teria jogado fora 23% do erro de contagem. É a tese da §3 medida contra o próprio autor.

E a fragilidade da seleção, medida — duas vezes. Para esse mesmo modelo de 124 épocas, a validação preferiu `A_full640` (4,27) a `B_full1280` (4,65) — **0,38 maçã em 81 imagens**, e no teste isso custou **31,1 contra 19,1: doze pontos de MAE decididos por ruído**. Entre os dois YOLO26s repetiu: a validação preferiu o **sem** augmentação por **0,90 maçã**, e no teste o **com** ganha por 2,45. Não troquei nenhuma escolha depois de ver o teste — as linhas da tabela são o que cada validação elegeu. **Calibrar numa única sessão é o elo mais fraco do pipeline**, e é aí que o próximo esforço deve ir, não em mais parâmetros.

Ressalva de escopo. n = 1 treino por condição, uma semente, só no fold 0 — cuja validação é uma sessão e cujo teste são três outras, daí os vieses de -18% a -63% aqui contra -2,0% do braço congelado da §4. Estas MAEs **ordenam** os modelos; não são números de produto. E um par não é ablação limpa: o YOLO11s muda arquitetura, cabeça e pré-treino além do tamanho. Os outros dois isolam: 9,9 M contra 21,8 M com a mesma augmentação, e o mesmo 9,9 M com e sem ela.

7. Deployment e bônus

Preparação para deployment. Congelar o ponto de operação — limiar, tile, política de fusão — como configuração versionada junto do checkpoint: o modelo sozinho não é o sistema. Exportar PyTorch → ONNX → engine TensorRT **construída no próprio Jetson** (a engine é específica de hardware e versão), FP16 antes de INT8, medindo latência do lote de tiles e não por tile. Em operação, monitorar deriva da contagem por fileira e manter um **canário rotulado por**

estufa, que dada a §5 é o item que mais importa. *Licença*: o Ultralytics é AGPL-3.0; produto embarcado fechado exigiria Enterprise ou um detector permissivo (RT-DETR, RF-DETR).

As latências deste relatório são de uma RTX 3050 Laptop, não de um Jetson: as razões entre braços transferem, os absolutos não.

Bônus: supressão de duplicatas entre quadros. Deslocamento estimado por correlação de fase em OpenCV, caixas do quadro anterior transportadas, casamento por sobreposição, contagem de **trilhas** em vez de detecções. Como nenhum dataset público rotula identidade entre quadros, a sequência é construída: uma janela varre cada imagem rotulada com deslocamento conhecido de 60 px, cinco posições.

Nas 668 imagens, a soma ingênua por quadro dá **100.392 — 3,56× a verdade**; após deduplicação, **28.180**, que é exatamente a contagem única verdadeira: **erro 0 em 668 de 668**.

Ressalva: o rastreador recebeu as anotações no lugar de detecções, o que isola o mecanismo e não mede desempenho de produto. Em **sequências reais** (26 trechos), 13.595 observações viram 5.538 trilhas, com $|dx|$ mediano de **27,6 px**, $|dy|/|dx| = 0,195$, e **12 trechos indo para +x e 14 para -x**. O estimador recupera sozinho que a câmera translada na horizontal com direção invertida entre sessões — exatamente o protocolo do artigo: caminhar por um lado da fileira e voltar pelo outro.

Modo de falha que esse regime esconde: a contagem única é o número de trilhas, sem comprimento mínimo — com detector real, cada falso positivo de um quadro cria uma trilha. Exigir que uma trilha apareça em ≥ 2 quadros é a primeira coisa a acrescentar, e vira um filtro de falso positivo de graça que a inferência quadro a quadro não tem como fazer.

8. O que eu faria em seguida

Priorizado pelo que a análise mostrou, não por intuição. Dois itens da lista anterior saíram dela porque viraram experimento (§6).

- 1. Consertar o domínio antes do modelo — e já há prova de que paga.** O erro dominante é deriva entre dias de captura, de -85% a +166% por sessão. A §6 testou atacar exatamente isso: ampliar a augmentação de brilho até cobrir a faixa das sessões que falham comprou **-16,2% de MAE e -10 pontos de viés** sem trocar uma linha de arquitetura — mais do que quadruplicar os parâmetros comprou. O caminho continua: cobertura de condições na captura, um protocolo que fixe exposição e distância, e **recalibração do limiar por estufa**.
- 2. Calibrar em mais de uma sessão, antes de qualquer coisa de modelo.** A §6 mede o custo do elo fraco: **doze pontos de MAE decididos por 0,38 maçã** de diferença na validação de uma sessão. Reservar duas sessões para calibração, ou escolher o ponto por pior-caso entre sessões em vez de média, custa um dia e vale mais que dobrar o modelo — que já mediu saturação.
- 3. Parar de subir o modelo.** A §6 mediu o joelho: 2,5 M $\rightarrow$ 9,9 M derruba a MAE de 24,7 para 15,1; e com a augmentação igualada, 9,9 M dá **12,6** contra **19,3** dos 21,8 M. Com 450 imagens de treino, capacidade acima de ~ 10 M vira decoração das seis sessões. A cabeça P2 (stride 4) segue *condicional* e agora menos provável — a §6 indica que a falta de resolução se resolve na entrada, não no mapa de features.
- 4. Terceiro braço de controle** — 10 sessões no treino, sem os quadros vizinhos do teste — para separar vazamento de cobertura de domínio.
- 5. Agrupar por fileira, não por sessão.** O teste oficial se chama `dataset1_front / dataset1_back` — cada fileira é filmada dos dois lados, e os dois lados não compartilham pixels: ORB + RANSAC sobre os **199.212 pares entre sessões** não achou **um único** com repetição de cena (máx. 13 *inliers*), contra **300/300** num controle de quadros vizinhos. Mas a fileira compartilha árvores e luz, e o dataset não expõe essa granularidade.

Siglas

MAE	erro absoluto médio de contagem, em maçãs	IoU	interseção ÷ união de duas caixas
MAPE	o mesmo, em % da contagem real	IoS	interseção ÷ área da menor — mata a duplicata de borda
AP / AP₅₀	<i>average precision</i> média em IoU 0,50–0,95 / fixa em 0,50	NMS	<i>non-maximum suppression</i> — descarta a caixa de menor score
AP-small	AP restrito a objetos < 32 ² px (69,5% deste dataset)	NMM	<i>non-maximum merging</i> — funde as duas na união
AR@300	<i>average recall</i> com até 300 detecções por imagem	TP/FP/FN	acerto / detecção sem anotação / anotação perdida
mAP	AP média entre classes — aqui há uma só, então mAP = AP	COCO	benchmark cujos cortes de área (<i>small/medium/large</i>) são usados
F1	média harmônica de precisão e recall, no ponto de operação	STAL	atribuição de rótulo do YOLO26, ciente de alvo pequeno
R²	concordância com a reta $y = x$; negativo = pior que prever a média	DFL	<i>distribution focal loss</i> — ausente no YOLO26, o que limpa o export
r²	ajuste de uma regressão livre — mais lisonjeiro, e não é o mesmo	ORB/RANSAC	detector de pontos e ajuste robusto, usados na busca por cena repetida